Introducción a la

Probabilidad y la Estadística

Cursado

Martes y Jueves

Aula B17

Docente

Dra. Ana Georgina Flesia

Método de los momentos

Momentos

1. Los momentos de X son

$$M_1 = E(X), \cdots, M_k = E(X^k)$$

supondremos que existen y son finitos.

2. Sea $X_1; \cdots; X_n$ un muestreo aleatorio de X, con distribución

$$p(x, \theta_1, \cdots, \theta_k) \text{ con } (\theta_1, \cdots, \theta_k) \in \mathbb{R}^k$$

Aquí p denota la densidad continua de X o la función de probabilidad discreta

3. Entonces el vector de momentos es una función de los θ_i:

$$(M_1, \cdots, M_k) = g(\theta_1, \cdots, \theta_k)$$

4. Denotamos

$$\overline{M}_j = \frac{1}{n} \sum_{i=1}^{n} X_i^j$$

los momentos muestrales.

Métodos de los Momentos

Método

El método de los momentos consiste en resolver el sistema de ecuaciones

$$(\overline{M}_1, \cdots, \overline{M}_k) = g(\hat{\theta}_1, \cdots, \hat{\theta}_k)$$

Es decir, los estimadores $\hat{\theta}_i; i = 1; \cdots; k$ están dados por

$$(\hat{\theta}_1, \cdots, \hat{\theta}_k) = g^{-1}(\overline{M}_1, \cdots, \overline{M}_k)$$

Este sistema no tiene porque tener solución, ni ser única, pero sí en todas las aplicaciones que veremos en el curso.

Ejemplo

1. Por ejemplo, supongamos que $X_1; \cdots ; X_n$ es un muestreo aleatorio de X que tiene densidad

$$p(x, \theta) = (\theta + 1)x^{\theta} \quad x \in [0, 1]$$

2. La esperanza de X es entonces

$$E(X) = (\theta + 1) \int_0^1 x^{\theta+1} dx = \frac{\theta + 1}{\theta + 2}$$

3. Esto quiere decir que la esperanza de X es una función del parámetro $g(\theta)$; en este caso

$$g(\theta) = \frac{\theta + 1}{\theta + 2}$$

4. Planteando la ecuación de estimación y resolviendo queda

$$\overline{X} = \frac{\hat{\theta} + 1}{\hat{\theta} + 2} \implies \hat{\theta} = \frac{1 - 2\overline{X}}{\overline{X} - 1}$$

y este es el estimador de momentos de θ.

Ejemplo

1. Por ejemplo, supongamos que $X_1; \cdots ; X_n$ es un muestreo aleatorio de X que tiene densidad

$$f_X(x) = \begin{cases} \frac{1}{2} + \frac{\beta x^3}{2} & -1 \leq x \leq 1 \\ 0 & \text{en cualquier otro caso} \end{cases}$$

donde $\beta \in [-1, 1]$.

2. La esperanza de X es entonces

$$E[X] = \int_{-\infty}^{\infty} x f_X(x)\, dx = \int_{-1}^{1} x \left(\frac{1}{2} + \frac{\beta x^3}{2} \right) dx = \int_{-1}^{1} \frac{x}{2} dx + \int_{-1}^{1} \frac{\beta x^4}{2} dx \tag{1}$$

$$= 0 + \left. \frac{\beta x^5}{25} \right|_{-1}^{1} = \frac{\beta}{5} \tag{2}$$

Ejemplo

1. Esto quiere decir que la esperanza de X es una función del parámetro $g(\beta)$; en este caso

$$g(\beta) = \frac{\beta}{5}$$

2. Planteando la ecuación de estimación y resolviendo queda

$$\overline{X} = \frac{\beta}{5} \implies \hat{\beta} = 5\overline{X}$$

y este es el estimador de momentos de β.

Verificar que el estimador es insesgado

Un estimador es insesgado si su esperanza es igual al parámetro verdadero.
Calculamos $E[\hat{\beta}]$:

$$E[\hat{\beta}] = E\left[5\bar{X}\right] = 5E[\bar{X}].$$

Dado que $\bar{X}$ es la media muestral, tenemos:

$$E[\bar{X}] = E[X] = \frac{\beta}{5}.$$

Por lo tanto:

$$E[\hat{\beta}] = 5 \cdot \frac{\beta}{5} = \beta.$$

Esto confirma que $\hat{\beta} = 5\bar{X}$ es un estimador insesgado para β.

Estimación de máxima verosimilitud

Estimación de Máxima Verosimilitud

- Sea $X_1; \cdots ; X_n$ una muestra aleatoria de X, con distribución

$$p(x, \theta_1, \cdots, \theta_k) \text{ con } (\theta_1, \cdots, \theta_k) \in \mathbb{R}^k$$

  Aquí p denota la densidad continua de X o la función de probabilidad discreta.
- Queremos estimar el vector de parámetros desconocidos $(\theta_1, \cdots, \theta_k)$ de la distribución.
- Definimos la función de verosimilitud de la muestra, esto es, la densidad conjunta de la muestra aleatoria en función del vector de parámetros, dejando fijo el conjunto de valores observados de la muestra.

$$L(\theta_1, \cdots, \theta_k) = p\left(\mathbf{x}_1, \ldots, \mathbf{x}_n | \theta_1, \cdots, \theta_k\right) = \prod_{i=1}^{n} p\left(\mathbf{x}_i | \theta_1, \cdots, \theta_k\right) \tag{1}$$

- La estimación de máxima verosimilitud (MV) es un método para encontrar los parámetros que mejor ajusten la función de

Estimación de Máxima Verosimilitud

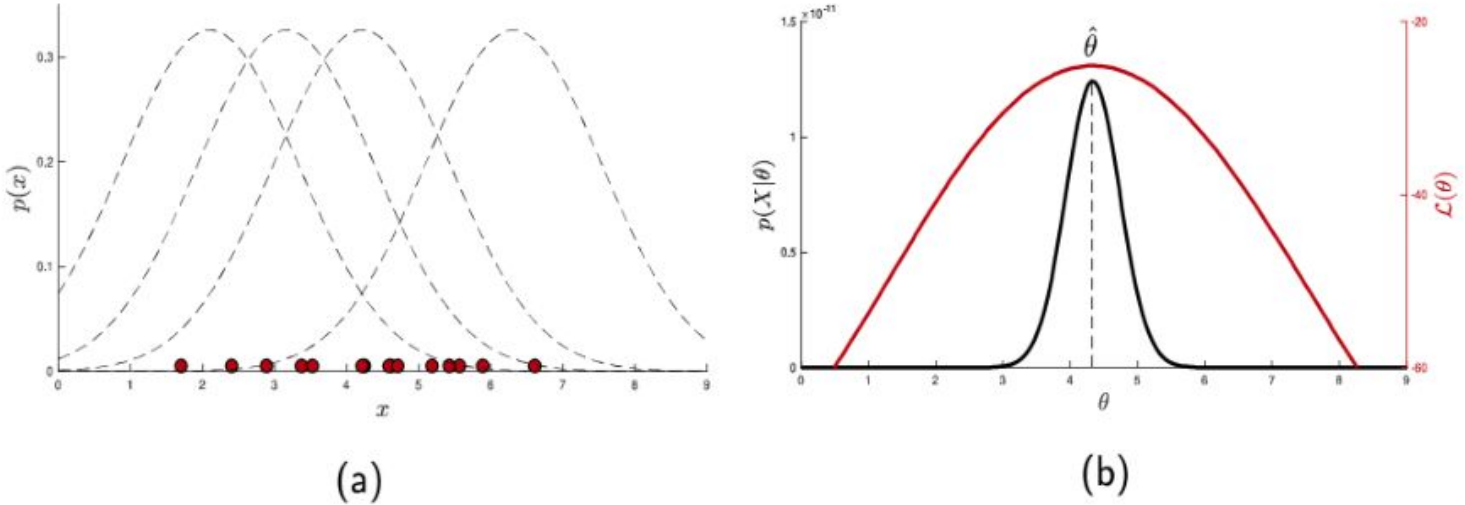
- Suponga que se quiere estimar un sólo parámetro $\boldsymbol{\theta}$, el estimador $\hat{\boldsymbol{\theta}}$ de máxima verosimilitud es el valor de $\boldsymbol{\theta}$ que maximiza la verosimilitud $L(\boldsymbol{\theta})$, esto es

$$\hat{\theta} = \arg\max_{\theta} \prod_{i=1}^{n} p\left(\mathbf{x}_i|\theta\right)$$

- Ese estadístico también realiza el máximo de la función de log-verosimilitud $\ell(\theta) \equiv \ln p\left(\mathbf{x}_1, \ldots, \mathbf{x}_n|\boldsymbol{\theta}\right)$, esto es

$$\hat{\theta} = \arg\max_{\theta} \sum_{i=1}^{n} \ln p\left(\mathbf{x}_i|\theta\right)$$

Estimación de Máxima Verosimilitud



(a) (b)

(a) Puntos en una dimensión tomados de una distribución Gaussiana con varianza específica y media desconocida. Se muestran cuatro de un número infinito de distribuciones fuente candidatas. (b) Verosimilitud (curva negra) y log-verosimilitud (curva roja) en función de la media. El valor que maximiza la verosimilitud es señalado con $\hat{\theta}$.

Estimación de Máxima Verosimilitud

- Generalizando la verosimilitud como una función de los k parámetros desconocidos $\boldsymbol{\theta} = (\theta_1, \ldots, \theta_k)$; el estimador vectorial de máxima verosimilitud es el vector $\hat{\boldsymbol{\theta}} = (\hat{\theta}_1, \ldots, \hat{\theta}_k)$ que maximiza la $\ell(\boldsymbol{\theta}) \equiv \ln p(\mathbf{x}|\boldsymbol{\theta})$

$$\hat{\boldsymbol{\theta}} = \arg\max_{\boldsymbol{\theta}} \sum_{i=1}^{n} \ln p\left(\mathbf{x}_i|\boldsymbol{\theta}\right)$$

- En la mayoría de los casos, esto se reduce a resolver la ecuación

$$\nabla_{\boldsymbol{\theta}} \mathcal{L}(\boldsymbol{\theta}) = \sum_{i=1}^{n} \nabla_{\boldsymbol{\theta}} \ln p\left(\mathbf{x}_i|\boldsymbol{\theta}\right) = \mathbf{0}$$

donde el operador gradiente es

$$\nabla_{\boldsymbol{\theta}} \equiv \left[\frac{\partial}{\partial\theta_1}, \ldots, \frac{\partial}{\partial\theta_k}\right]^T$$

Estimación de Máxima Verosimilitud

Principio de Invarianza

Si $\hat{\theta}$ es el estimador de máxima verosimilitud de θ, entonces $h(\hat{\theta})$ es el estimador de máxima verosimilitud de $h(\theta)$.

Observación

- En general, cuando la función de verosimilitud es diferenciable en el parámetro θ, para calcular $\hat{\theta}$ derivamos $\ell_n(\theta)$ respecto de θ e igualamos a cero.
- En general se trata siempre de un máximo, aunque para verificarlo deberíamos calcular el signo de la derivada segunda $\ell_n''(\theta)$ y ver que es negativo.
- Cuando $L_n(\theta)$ no es diferenciable, cosa que sucede típicamente cuando el dominio de $L_n(\theta)$ depende de θ, hallar en dónde se da el máximo es más difícil y no se puede hacer derivando.

Ejemplo: Caso Bernoulli

Supongamos que $X_1, \ldots, X_n \sim \mathrm{Ber}(p)$. El logaritmo de la función de verosimilitud es

$$\ell_n(p) = \sum_{i=1}^{n} X_i \ln(p) + (1 - X_i) \ln(1 - p)$$

de donde vemos que

$$\begin{cases} \ell_n'(p) = n \left[\frac{\bar{X}_n}{p} - \frac{1-\bar{X}_n}{1-p} \right] \\ \ell_n''(p) = -n \left[\frac{\bar{X}_n}{p^2} + \frac{1-\bar{X}_n}{(1-p)^2} \right] \end{cases}$$

Notar que $\ell_n''(p) < 0$ para todo $p \in (0, 1)$, por lo que el punto crítico es un máximo. Se puede deducir entonces que $T_n = \bar{X}_n$. Es decir, el estimador de máxima verosimilitud es el promedio.

Ejemplo: Caso uniforme

- Supongamos que $X_1, \ldots, X_n \sim U(0, \theta)$. La función de verosimilitud no es continua, y está dada por

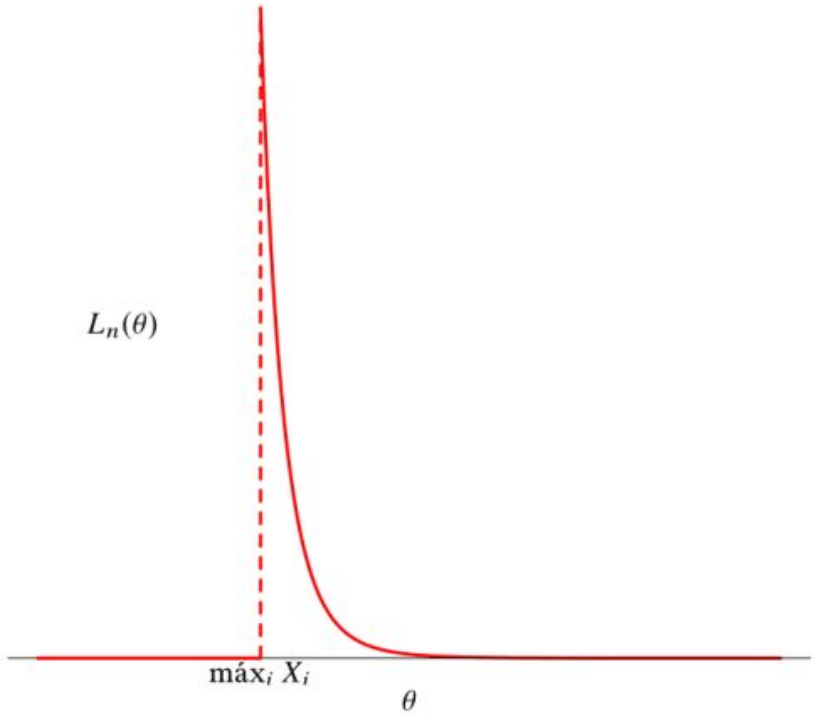
$$L_n(\theta) = \begin{cases} \frac{1}{\theta^n} & \text{si } X_i < \theta \ \forall i \\ 0 & \text{si no.} \end{cases}$$

- Decir que $X_i < \theta$ para todo i es equivalente a decir que $\max_i X_i < \theta$. Entonces podemos reescribir la función de verosimilitud como

$$L_n(\theta) = \begin{cases} \frac{1}{\theta^n} & \text{si } \max_i X_i < \theta \\ 0 & \text{si no.} \end{cases}$$

- Es claro que el máximo se da en $T_n = \max_i X_i$, que es por lo tanto el estimador de máxima verosimilitud de θ.

Ejemplo: Caso uniforme



$U[0, \theta]$

El estimador de máxima verosimilitud de θ es sesgado.

- Supongamos que tenemos n variables aleatorias $X_1, X_2, \ldots, X_n$ que son iid y distribuidas uniformemente en $[0, \theta]$.
- La CDF de cada X_i es:

$$F_X(x) = \begin{cases} 0 & \text{si } x < 0 \\ \frac{x}{\theta} & \text{si } 0 \leq x \leq \theta \\ 1 & \text{si } x > \theta \end{cases}$$

- Definimos el máximo de la muestra como $M = \max(X_1, X_2, \ldots, X_n)$.

$U[0, \theta]$

- La CDF del máximo se puede calcular como:

$$\begin{aligned} F_M(m) &= P(M \leq m) = P(X_1 \leq m, X_2 \leq m, \ldots, X_n \leq m) \\ &= P(X_1 \leq m)^n \\ &= (F_X(m))^n \end{aligned}$$

Para $0 \leq m \leq \theta$:

$$F_M(m) = \left(\frac{m}{\theta}\right)^n$$

- Para encontrar la función de densidad del máximo, derivamos la CDF:

$$\begin{aligned} f_M(m) &= \frac{d}{dm} F_M(m) \\ &= \frac{d}{dm} \left(\frac{m}{\theta}\right)^n \\ &= \frac{n}{\theta^n} m^{n-1} \end{aligned}$$

para $0 \leq m \leq \theta$.

$U[0, \theta]$

- Para determinar si el estimador del máximo $M = \max(X_1, X_2, \ldots, X_n)$ de una muestra de variables aleatorias X_i uniformes en el intervalo $[0, \theta]$ es insesgado, debemos calcular su valor esperado $E[M]$ y compararlo con θ.
- Usamos la función de densidad del máximo:

$$E[M] = \int_0^\theta m \cdot f_M(m)\, dm = \int_0^\theta m \cdot \frac{n}{\theta^n} m^{n-1}\, dm = \frac{n}{\theta^n} \int_0^\theta m^n\, dm$$

$U[0, \theta]$

- La integral $\int_0^\theta m^n \, dm$ se evalúa como:

$$\int_0^\theta m^n \, dm = \left[\frac{m^{n+1}}{n+1} \right]_0^\theta = \frac{\theta^{n+1}}{n+1}$$

- Sustituyendo en la expresión para $E[M]$:

$$E[M] = \frac{n}{\theta^n} \cdot \frac{\theta^{n+1}}{n+1} = \frac{n\theta}{n+1}$$

- Vemos que:

$$E[M] = \frac{n\theta}{n+1}$$

Esto implica que $E[M]$ no es igual a θ, lo que significa que el estimador M es sesgado.

- Para que sea insesgado, podemos considerar un estimador corregido, por ejemplo, $\hat{\theta} = \frac{n+1}{n} M$, que tiene un valor esperado:

$$E\left[\hat{\theta}\right] = E\left[\frac{n+1}{n} M\right] = \frac{n+1}{n} E[M] = \frac{n+1}{n} \cdot \frac{n\theta}{n+1} = \theta$$

Por lo tanto, el máximo M es sesgado, pero el estimador $\hat{\theta} = \frac{n+1}{n} M$ es insesgado.

Ejemplo: Caso uniforme

$U[\theta, 1]$

Sea $X_1, \cdots, X_n$ una muestra aleatoria de una distribución uniforme en el intervalo $[\theta, 1]$ con $\theta > 0$. Veamos que el estimador de máxima verosimilitud de θ es $\hat{\theta} = \min(X_i)$.

- Dada una muestra aleatoria $X_1, \ldots, X_n \sim \text{Unif}[\theta, 1]$ con $\theta > 0$, la función de densidad para cada X_i es:

$$f_X(x; \theta) = \frac{1}{1-\theta} \cdot \mathbb{I}_{[\theta,1]}(x)$$

- La función de verosimilitud de la muestra es el producto de las densidades individuales:

$$L(\theta) = \prod_{i=1}^{n} \frac{1}{1-\theta} \mathbb{I}_{[\theta,1]}(x_i) = \frac{1}{(1-\theta)^n} \mathbb{I}_{\{\theta \leq \min(x_i), \max(x_i) \leq 1\}}$$

Ejemplo: Caso uniforme

- Para que $L(\theta) > 0$, se debe cumplir que $\theta \leq \min(X_i)$.
- Como la función $L(\theta) = \frac{1}{(1-\theta)^n}$ es estrictamente creciente con respecto a θ en el intervalo $(0, \min(X_i)]$, alcanza su valor máximo en el límite superior del dominio permitido para θ:

$$\hat{\theta} = \min(X_i)$$

Ejemplo: Caso uniforme

$U[\theta, 1]$

¿Cual es la distribución acumulada de $\hat{\theta}$? ¿ y la densidad de $\hat{\theta}$?.

- Para cada $X_i \sim \text{Unif}[\theta, 1]$, la densidad y la distribución acumulada son:

$$f_X(x) = \frac{1}{1-\theta} \text{ para } \theta \leq x \leq 1$$

$$F_X(x) = \frac{x-\theta}{1-\theta} \text{ para } \theta \leq x \leq 1$$

- Sea $Y = \hat{\theta} = \min(X_i)$. Calculamos primero $P(Y > y)$:

$$P(Y > y) = P(\min(X_1, \ldots, X_n) > y) = \prod_{i=1}^{n} P(X_i > y) = (1 - F_X(y))^n$$

Ejemplo: Caso uniforme

- Sustituyendo

$$1 - F_X(y) = 1 - \frac{y-\theta}{1-\theta} = \frac{1-y}{1-\theta}$$

resulta

$$P(Y > y) = (1 - F_X(y))^n = \left(\frac{1-y}{1-\theta}\right)^n$$

si $\theta \leq y \leq 1$.

Ejemplo: Caso uniforme

- Función de distribución acumulada ($F_{\hat{\theta}}(y) = 1 - P(Y > y)$):

$$F_{\hat{\theta}}(y) = \begin{cases} 0 & \text{si } y < \theta \\ 1 - \left(\frac{1-y}{1-\theta}\right)^n & \text{si } \theta \leq y \leq 1 \\ 1 & \text{si } y > 1 \end{cases}$$

- Función de densidad de probabilidad ($f_{\hat{\theta}}(y) = \frac{d}{dy} F_{\hat{\theta}}(y)$):

$$f_{\hat{\theta}}(y) = \frac{n(1-y)^{n-1}}{(1-\theta)^n} \quad \text{para } \theta \leq y \leq 1$$

Ejemplo: Caso uniforme

$U[\theta, 1]$

El estimador de máxima verosimilitud de θ es sesgado, pero que $(n+1)\hat{\theta}/n$ es insesgado.

- Calculamos el valor esperado de $\hat{\theta}$:

$$E[\hat{\theta}] = \int_{\theta}^{1} y \cdot \frac{n(1-y)^{n-1}}{(1-\theta)^n}\, dy$$

- Haciendo la sustitución $u = 1 - y$. Entonces, $dy = -du$; si $y = \theta \implies u = 1 - \theta$, si $y = 1 \implies u = 0$:

$$E[\hat{\theta}] = \int_{0}^{1-\theta} (1-u) \cdot \frac{n u^{n-1}}{(1-\theta)^n}\, du = \frac{n}{(1-\theta)^n} \left[\int_{0}^{1-\theta} u^{n-1}\, du - \int_{0}^{1-\theta} u^{n}\, du \right]$$

Ejemplo: Caso uniforme

- Entonces

$$\begin{aligned} E[\hat{\theta}] &= \frac{n}{(1-\theta)^n}\left[\frac{(1-\theta)^n}{n} - \frac{(1-\theta)^{n+1}}{n+1}\right] \\ &= 1 - \frac{n}{n+1}(1-\theta) \\ &= \frac{n\theta+1}{n+1} \end{aligned}$$

- Sesgo de $\hat{\theta}$:

$$\text{Sesgo}(\hat{\theta}) = E[\hat{\theta}] - \theta = \frac{n\theta+1}{n+1} - \theta = \frac{1-\theta}{n+1} \neq 0$$

- Dado que $\theta < 1$, el sesgo es positivo, por lo que el estimador de máxima verosimilitud es sesgado.

Ejemplo: Caso uniforme

$U[\theta, 1]$

El estimador $\tilde{\theta} = \frac{(n+1)\hat{\theta}-1}{n}$ es insesgado

$$
\begin{aligned}
E\left[\frac{(n+1)\hat{\theta}-1}{n}\right] &= \frac{(n+1)E[\hat{\theta}]-1}{n} \\
&= \frac{(n+1)\left(\frac{n\theta+1}{n+1}\right)-1}{n} \\
&= \frac{n\theta+1-1}{n} = \theta
\end{aligned}
$$

Ejemplo: Caso uniforme

$U[\theta, 1]$

El estimador $2\bar{X} - 1$ es un estimador insesgado para θ.

- Para una variable $X_i \sim \text{U}[\theta, 1]$, la esperanza teórica es el punto medio del intervalo:

$$E[X_i] = \frac{\theta + 1}{2}$$

- Por la linealidad de la esperanza, para la media muestral $\bar{X}$:

$$E[\bar{X}] = \frac{\theta + 1}{2}$$

- Por lo tanto, la combinación lineal insesgada basada en la media es $\hat{\theta}_2 = 2\bar{X} - 1$:

$$E[2\bar{X} - 1] = 2E[\bar{X}] - 1 = 2\left(\frac{\theta + 1}{2}\right) - 1 = \theta$$

Ejemplo: Caso uniforme

$U[\theta, 1]$

¿Cual es el mejor Estimador?

- Para elegir entre los dos estimadores insesgados, comparamos sus varianzas:
- Varianza de $\hat{\theta}_2 = 2\bar{X} - 1$:

$$\text{Var}(X_i) = \frac{(1-\theta)^2}{12} \implies \text{Var}(\bar{X}) = \frac{(1-\theta)^2}{12n}$$

$$\text{Var}(\hat{\theta}_2) = 4\text{Var}(\bar{X}) = \frac{(1-\theta)^2}{3n} = O\left(\frac{1}{n}\right)$$

- Varianza del estimador basado en el mínimo $\tilde{\theta}$: Calculando $E[\hat{\theta}^2]$ se obtiene que $\text{Var}(\tilde{\theta})$ disminuye a una tasa de $O\left(\frac{1}{n^2}\right)$.

Ejemplo: Caso uniforme

Conclusión:

Se elige el estimador corregido basado en el mínimo $\tilde{\theta} = \frac{(n+1)\min(X_i)-1}{n}$ porque su varianza es significativamente menor para cualquier tamaño muestral $n > 1$, lo que lo convierte en un estimador más eficiente (menor Error Cuadrático Medio).